

TÍTULO PROVISÓRIO Viés de Gênero no Pagode

Amanda Schmielecki Cossa Manfredini¹, Karin Becker¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)

Porto Alegre – RS – Brasil

a3schmielecki@gmail.com, karin.becker@inf.ufrgs.br

Resumo

Este estudo investiga a presença de viés de gênero em músicas brasileiras de pagode a partir de um recorte de um corpus originalmente composto por 146.612 canções brasileiras. Inicialmente, foram identificadas 9.411

1 Introdução

Parágrafo 1: Falar sobre a importância da música

Parágrafo 2: Falar sobre a importância do pagode como representação cultural brasileira Falar sobre o q meu trabalho tem de diferentes dos outros

Ok, Chen já aplicou, bertopic e sc-weat, Betti aplicou sc-weat e Lopes construiu e analisou um corpus em português, o meu é diferente do dele pq tem a construção de alvos e atributos próprios, aplicação em músicas em português, em especial o pagode pro pmi e sc-weat pra geral. O meu difere desses trabalhos pq nenhum utilizou pmi e nenhum tratava sobre pagode.

Pro trabalho ficar muito forte precisa de uma contribuição computacional, se não der, a novidade vai ser descoberta de informações/análise exploratória, não q seja ruim, mas tb não é o ideal.

Este estudo investiga a presença de viés de gênero em letras brasileiras de pagode a partir de um recorte do corpus de Lopes et al. (2025). A análise foi conduzida por meio dos métodos PMI e SC-WEAT, com o objetivo de medir associações entre termos associados ao feminino e ao masculino e categorias semânticas de atributos, como agradabilidade, desagradabilidade, aparência, inteligência, força e fraqueza.

Diferentemente de Lopes et al. (2025), que analisam sentenças predicativas e profissões associadas ao gênero em um corpus amplo de músicas brasileiras, este estudo utiliza listas lexicais de alvos e atributos. Assim, enquanto o trabalho anterior observa como mulheres e homens são descritos em sentenças predicativas, esta pesquisa examina como termos associados ao feminino e ao masculino aparecem próximos de categorias como agradabilidade, desagradabilidade, aparência, inteligência, força e fraqueza no contexto lexical das letras de pagode.

2 Metodologia

2.1 Seleção e limpeza do corpus

O estudo parte do corpus de Lopes et al. (2025), originalmente composto por 146.612 letras de músicas brasileiras. A partir desse corpus, foram identificadas 9.485 músicas associadas ao pagode. Na etapa de limpeza, foram removidas 11 músicas em outros idiomas, 62 músicas repetidas e uma música cuja letra indicava “Letra não encontrada”, resultando em um corpus final de 9.411 músicas. Foram mantidas músicas com indicação de gravação ao vivo ou regravadas por artistas diferentes, pois essas versões podem circular em contextos distintos e atingir públicos diferentes; assim, apenas duplicações diretas foram excluídas.

2.2 Construção das listas de alvos e atributos

As listas de alvos e atributos foram construídas a partir de Chen et al. (2025), cujas categorias semânticas foram traduzidas, adaptadas e ampliadas para o português brasileiro e para o domínio do pagode. Neste estudo, os termos associados ao feminino e ao masculino foram tratados como alvos de gênero, pois o PMI parte da identificação desses termos nas letras para observar os atributos em seus contextos. No SC-WEAT, manteve-se a lógica de associação entre categorias semânticas e conjuntos de comparação de gênero.

A ampliação dos alvos considerou variações de gênero, número, diminutivo e aumentativo, além de nomes próprios recorrentes nas letras. Os alvos foram normalizados por conversão para minúsculas e remoção de caracteres não alfanuméricos, mas sem lematização e com preservação de acentos, para manter distinções como “avô”/“avô” e “vovô”/“vovô”. A Tabela 1 apresenta o total final de alvos utilizados.

Tabela 1: Número de alvos femininos e masculinos presentes na lista original do artigo de referência, entradas acrescentadas neste estudo e total final utilizado na análise.

Categoria	Lista original	Novas entradas	Total
Feminino	25	114	139
Masculino	22	194	216

A ampliação também foi apoiada nos dados e procedimentos de Lopes et al. (2025), que disponibilizam 120 padrões de busca para construções predicativas. A partir desses padrões, o artigo obteve 15.223 sentenças com predicativos femininos e 15.081 com predicativos masculinos. Neste trabalho, o recorte das ocorrências cujo gênero musical continha pagode, incluindo rótulos combinados como pagode/funk, resultou em 1.523 construções predicativas. Nessas ocorrências, sujeitos foram analisados como possíveis alvos de gênero e predicativos como possíveis atributos.

Os atributos foram organizados nas categorias Agradável, Desagradável, Aparência, Inteligência, Força e Fraqueza. Diferentemente dos alvos, eles foram normalizados e lematizados para reduzir redundâncias flexionais; quando duas formas eram reduzidas ao mesmo lema, apenas uma forma canônica foi mantida. Termos ambíguos, pouco informativos ou inadequados ao contexto das letras não foram incorporados. A Tabela 2 apresenta a distribuição final dos 331 atributos utilizados.

Tabela 2: Número de atributos mantidos da lista original do artigo de referência, entradas acrescentadas neste estudo e total final utilizado na análise.

Categoria	Lista original mantida	Novas entradas	Total
Agradável	27	75	102
Desagradável	32	71	103
Aparência	25	31	56
Inteligência	22	0	22
Força	15	11	26
Fraqueza	15	7	22

As decisões de inclusão, exclusão e adaptação dos termos foram registradas para garantir rastreabilidade metodológica. Dados e códigos disponíveis em: <https://github.com/amandaschmielecki/Pagode-pmi-sc-weat>

2.3 Configuração dos métodos PMI e SC-WEAT

O PMI foi empregado como medida de associação lexical local entre termos de gênero e categorias semânticas de atributos, permitindo identificar quais atributos aparecem próximos de alvos femininos e masculinos nas letras de pagode. Para isso, foi utilizada uma janela de quatro tokens antes e quatro depois de cada ocorrência de alvo, com remoção do próprio alvo da janela. Cada ocorrência gerou um contexto, sem deduplicação, pois repetições em letras musicais fazem parte da recorrência textual do corpus. O cálculo utilizou suavização de 0,5 e considerou atributos com pelo menos uma ocorrência no conjunto analisado.

O SC-WEAT, derivado do WEAT de Caliskan, Bryson e Narayanan (2017), foi utilizado para medir associações entre categorias semânticas e conjuntos de comparação de gênero em embeddings. Para isso, foi treinado um modelo Word2Vec no próprio corpus, com dimensão 100, janela 5, frequência mínima 1, algoritmo *skip-gram*, 50 épocas e semente fixa. A frequência mínima 1 foi mantida para preservar termos pouco frequentes das listas, e o *skip-gram* foi adotado por sua adequação a palavras menos frequentes.

No PMI, não foi aplicada remoção geral de stopwords, pois isso poderia alterar artificialmente a proximidade local entre alvos e atributos. No SC-WEAT, as stopwords foram removidas no pré-processamento do corpus usado para treinamento vetorial, preservando-se os termos das listas de alvos e atributos. A significância estatística foi estimada com 1000 permutações, e os conjuntos masculino/feminino e os pares de atributos foram balanceados por frequência para reduzir efeitos de diferenças de tamanho entre listas.

3 Resultados

4 Limitações

Algumas limitações devem ser consideradas na interpretação dos resultados. A lematização pode não reconhecer adequadamente formas informais, abreviadas ou estilizadas frequentes em letras de música, como “louquin” ou “pretin”. Além disso,

no PMI, a proximidade em uma janela de contexto não garante que o atributo esteja sintaticamente ligado ao alvo. Por exemplo, em “eu tô bolado, ela quer beijo na boca”, termos próximos podem ser associados ao alvo “ela”, mesmo que parte deles se refira a outro sujeito ou a outro trecho da frase.

Também não foram utilizados como alvos termos como “eu” e “você”, pois eles podem se referir tanto a pessoas femininas quanto masculinas, dependendo do contexto da música. Essa ambiguidade dificulta uma classificação segura de gênero e poderia introduzir ruído na análise.

5 Conclusão

Referências

Betti, L., Abrate, C., and Kaltenbrunner, A. (2023). Large scale analysis of gender bias and sexism in song lyrics. *EPJ Data Science*, 12(1):10. DOI: 10.1140/epjds/s13688-023-00384-8.

Caliskan, A., Bryson, J. J., and Narayanan, A. (2017). Semantics Derived Automatically from Language Corpora Contain Human-Like Biases. *Science*, 356(6334):183–186. DOI: 10.1126/science.aal4230.

Chen, D., Satish, A., Khanbayov, R., Schuster, C. M., and Groh, G. (2025). Tuning Into Bias: A Computational Study of Gender Bias in Song Lyrics. In *Proceedings of the 9th Joint SIGHUM Workshop on Computational Linguistics for Cultural Heritage, Social Sciences, Humanities and Literature*, pages 117–129, Albuquerque, New Mexico. Association for Computational Linguistics. DOI: 10.18653/v1/2025.latechclfl-1.12.

Church, K. W. and Hanks, P. (1990). Word Association Norms, Mutual Information, and Lexicography. *Computational Linguistics*, 16(1):22–29.

Lopes, J. N. S., Firmino, V. P., and Reis, V. Q. (2025). Muses or Stereotypes? Identifying Historical Patterns of Sexism in a Corpus of Brazilian Lyrics. *Journal on Interactive Systems*, 16:1. DOI: 10.5753/jis.2025.5233.